

Guía de figuras

Qué contesta cada gráfica del proyecto, con un ejemplo real de cada tipo

Andrés García Rivera

21 de septiembre de 2026

Resumen

El proyecto produce unas cuatrocientas figuras por campaña, de catorce tipos distintos. Este documento enseña a leer cada tipo: qué hay en cada eje, qué pregunta contesta, qué hay que mirar primero y qué cuenta como un valor alarmante. Todos los ejemplos son figuras reales de la campaña `hpc_20260907_182345` (Saptiva), no ilustraciones hechas a mano.

La regla que ordena todo el documento: **cada figura contesta una pregunta**. Si no sabes qué pregunta contesta, no la metas en el paper.

Índice

1. Los tres ejes	2
2. Por campaña: la carpeta <code>hpc_*</code>	3
2.1. <code>convergence_<modelo></code> — ¿bastan los qubits que usé?	3
2.2. <code>cost_<modelo></code> — qué cuesta cada peldaño	3
2.3. <code>convergence_<modelo>_genetico</code> — la rejilla del genético	4
2.4. <code>cost_<modelo>_genetico</code>	5
3. Por tarea: la escalera de quantumness	6
3.1. <code>ladder_trends_<modelo></code> — la figura central del marco	6
3.2. <code>ladder_summary_<modelo></code> — los mismos números, en tabla	6
3.3. <code>ladder_rhat_qmcmc_<modelo></code> — ¿convergió la cadena?	7
3.4. <code>ladder_kl_qvmc_<modelo></code> — el techo del ansatz	8
3.5. <code>corner_ladder_<familia>_<modelo></code> — la prueba visual	8
3.6. <code>corner_ladder_1to1_*</code> — peldaño contra peldaño	9
4. Por tarea: los genéticos	10
4.1. <code>fitness_<modelo>_fitness</code>	10
4.2. <code>genetic_convergence_<modelo></code>	10
5. El eje de ruido	12
5.1. Las métricas, y qué cuenta como alarmante	12
5.2. <code>ruido_vs_rejilla_<familia>_<modelo>_<métrica></code>	12
5.3. <code>ruido_fijo_<familia>_<modelo>_<rejilla></code>	13
6. Las comparaciones	15
6.1. <code>eficiencia_QMCMC100</code> y <code>eficiencia_QMCMC50</code>	15
6.2. <code>incertidumbre_reportada</code>	15
6.3. <code>genetico_chi2grid</code>	16
6.4. <code>modelos_aic_bic</code>	17

7. Índice rápido	18
8. Cómo rehacerlas todas	18
9. Lo que no hay que hacer con estas figuras	18

1. Los tres ejes

Todo el marco se mueve en tres ejes independientes, y cada figura vive en uno de ellos. Saber en cuál está es la mitad de leerla.

eje	qué se mueve	figuras
tamaño del registro	nqpp (qubits por parámetro, en los samplers) o n_bits (bits por gen, en el genético)	convergence_*, cost_*, ruido_vs_rejilla_*
quantumness	de 0% a 100% de componentes cuánticos encendidos	ladder_*, corner_ladder_*, fitness_*
ruido	none / readout / full / FakeBrisbane	ruido_vs_rejilla_*, ruido_fijo_*

Ojo con una trampa: nqpp y n_bits viven en la *misma* columna del CSV pero **no son la misma cantidad**. Para los samplers es cuántos qubits se usan por cada parámetro de la rejilla del posterior; para el genético es cuántos bits tiene cada gen de la codificación. Ponerlas en un mismo eje junta dos números incomparables. Por eso las figuras del genético llevan el sufijo `_genetico` y su propio eje: son dos figuras separadas, a propósito.

2. Por campaña: la carpeta `hpc_*`

Son diez figuras por campaña y por familia. Se rehacen con `cosmo_hpc_runner.py -plot-only`.

2.1. `convergence_<modelo>` — ¿bastan los qubits que usé?

Archivo: `convergence_lcdm.{png,pdf}`

Un panel por parámetro cosmológico. Eje x : `nqpp`. Una curva por método, con banda de $\pm\sigma$. Las líneas horizontales de Planck 2018 y SH0ES son referencias externas, *no* ajustes de este trabajo.

Qué contesta: ¿Cambia el resultado si le doy más qubits al circuito? Si las curvas son planas, no — y eso es bueno: quiere decir que con 3 ya basta y que subir a 5 no compra nada, sólo cuesta.




Figura 1: Λ CDM. Las curvas son esencialmente planas entre `nqpp`= 3 y 5: el resultado no depende del tamaño del registro. La única que se mueve es QVMC 67 % (verde oliva) en `nqpp`= 4, y vuelve a la línea en 5. Las bandas de $\pm\sigma$ se solapan por completo, así que ese movimiento no es significativo.

Qué mirar primero: si una curva *sí* tiene pendiente, el resultado depende de una elección de implementación y no sólo de los datos. Eso hay que reportarlo, no promediarlo.

2.2. `cost_<modelo>` — qué cuesta cada peldaño

Archivo: `cost_lcdm.{png,pdf}`

Tiempo de pared contra `nqpp`, una curva por método.

Qué contesta: Cuánto cuesta cada método **en el simulador**. Nada más.




Figura 2: Λ CDM. Los dos peldaños del QMCMC (morado y café) están pegados al eje; los del QVMC suben tres órdenes de magnitud. Esta figura mide **Aer**, no hardware cuántico: no sostiene ninguna afirmación sobre velocidad real.

Limitación conocida. Esta figura **junta todos los niveles de ruido** en una sola curva por método. Por eso una curva puede bajar al crecer n_{qpp} : no es que el problema se abarate, es que los puntos de la derecha vienen de celdas sin ruido y los de la izquierda de celdas ruidosas. Léela como un orden de magnitud. Para el tiempo celda por celda, usa el panel de tiempo de ruido_fijo_* o la columna Time_s del CSV, que sí separan por nivel de ruido.

2.3. convergence_<modelo>_genetico — la rejilla del genético

Archivo: convergence_lcdm_genetico.{png,pdf}

Lo mismo que arriba pero con eje $x = n_{bits}$ y sólo los métodos genéticos.

Qué contesta: ¿Cuántos bits por gen hacen falta para que el genético deje de depender de la codificación?




Figura 3: Λ CDM. QGA 67% (rojo) arranca en $\Omega_m = 0,270$ con $n_{bits}=4$ y converge a 0,2765 a partir de 6. Los peldaños de 0% y 33% salen marcados como *n_bits-independent*: no dependen de la codificación porque sus operadores no la tocan. **La lectura es que con 4 bits la rejilla es demasiado gruesa** y por debajo de 6 no conviene reportar.

2.4. cost_<modelo>_genetico

Archivo: cost_lcdm_genetico.{png,pdf}

Qué contesta: Dónde se vuelve impagable el genético cuántico.




Figura 4: El peldaño de 100 % es el que dispara el costo, porque el operador de cruce usa $2n_b$ qubits y con matriz de densidad eso crece muy rápido. Es la razón por la que el QGA 100% con ruido es inviable a partir de $n_b = 6$.

3. Por tarea: la escalera de quantumness

Viven dentro de la carpeta de cada tarea de samplers. Se rehacen con la opción `--replot-ladder` del módulo principal.

3.1. `ladder_trends_<modelo>` — la figura central del marco

Archivo: `ladder_trends_lcdm.{png,pdf}`

Rejilla de 8 a 10 paneles. Eje x: porcentaje de quantumness (0 → 100), un punto por peldaño. Rojo = QMCMC, naranja = QVMC. Un panel por parámetro cosmológico, más runtime, χ^2_V , AIC, BIC, ESS y aceptación/KL.

Qué contesta: Qué cambia, y sobre todo qué *no* cambia, al ir encendiendo componentes cuánticos.




Figura 5: Λ CDM, nqpp= 3. En los paneles de Ω_m y H_0 las dos series son **líneas planas**: encender componentes cuánticos no mueve los parámetros. Eso es exactamente la afirmación de fidelidad. Lo que sí cambia es el runtime, que salta de ~ 450 a ~ 1500 segundos entre el 33 % y el 67 % del QVMC.

Qué mirar primero: los paneles de parámetros. Plano es el resultado deseado. Si se inclinan, la quantumness está cambiando la física, que es justo lo que el marco existe para detectar.

3.2. `ladder_summary_<modelo>` — los mismos números, en tabla

Archivo: `ladder_summary_lcdm.{png,pdf}`

Qué contesta: Los valores exactos, para citarlos sin tener que leerlos de una gráfica.

Flat Λ CDM — per-method quantumness ladders
steps=20000 | iters=15000 | nqpp=3

method/level	Om	H0	chi2_red	AIC	time	acc	ESS	KL
QMCMC 0%	0.2764±0.0105	69.59±0.80	0.970	1068.6	16.8s	0.487	6872	—
QMCMC 50%	0.2764±0.0104	69.60±0.80	0.970	1068.6	105.6s	0.456	6956	—
QMCMC 100%	0.2764±0.0104	69.60±0.80	0.970	1068.6	142.4s	0.456	6956	—
QVMC 0%	0.2757±0.0101	69.54±0.88	0.970	1068.6	449.1s	—	12288	1.6250
QVMC 33%	0.2755±0.0102	69.55±0.90	0.970	1068.6	452.4s	—	12288	1.6250
QVMC 67%	0.2754±0.0099	69.56±0.89	0.970	1068.6	1504.9s	—	12288	1.6286
QVMC 100%	0.2754±0.0099	69.56±0.89	0.970	1068.6	1529.3s	—	12288	1.6286

Figura 6: Aquí se ven de golpe las dos parejas fieles: QMCMC 50% y 100% dan $0,2764 \pm 0,0104$ idéntico, y QVMC 67% y 100% dan $0,2754 \pm 0,0099$ idéntico. También se ve que el ESS del variacional es 12288 en los cuatro peldaños: ahí el ESS es el número de disparos, no una medida de calidad, y por eso no se compara entre familias.

3.3. ladder_rhat_qmcmc_<modelo> — ¿convergió la cadena?

Archivo: ladder_rhat_qmcmc_lcdm.{png,pdf}

$\hat{R} - 1$ contra pasos de muestreo, eje y logarítmico, una curva por peldaño. La línea punteada es el umbral $\hat{R} - 1 = 0,01$.

Qué contesta: ¿Convergió la cadena, y convergió igual de rápido en todos los peldaños?




Figura 7: Las dos curvas cruzan el umbral cerca de los 2500–3000 pasos y terminan en $\hat{R} - 1 \approx 10^{-3}$, muy por debajo del criterio. El peldaño cuántico (rojo) tarda un poco más en cruzar pero acaba igual. Que las dos curvas se persigan sin separarse es otra forma de ver la fidelidad.

Criterio duro: si una curva no baja del umbral, esa celda **no es citable**. No se sabe siquiera si la lista de puntos es una muestra de la posterior, y entonces la barra de error no significa nada.

3.4. ladder_kl_qvmc_<modelo> — el techo del ansatz

Archivo: ladder_kl_qvmc_cpl.{png,pdf}

KL contra iteración de entrenamiento, **logarítmico en los dos ejes**.

Qué contesta: (1) ¿A qué valor se estanca el entrenamiento? (2) ¿Cuántas iteraciones gastó cada peldaño?




Figura 8: CPL, nqpp= 3. Las cuatro curvas bajan y se aplanan. Ese piso **es el techo de expresividad del ansatz**: con $n(2L+1) = 7n$ ángulos contra $2^n - 1$ grados de libertad, la KL no puede llegar a cero y no hay que esperar que lo haga. No es un fallo de convergencia.

Y aquí hay algo que sí hay que explicar en el paper. Los peldaños **no gastan el mismo número de iteraciones**: el de 33 % llega a $\sim 10^5$ mientras los de 67 % y 100 % paran en $1,5 \times 10^4$. No es un error. El presupuesto se iguala por **circuitos**, no por iteraciones, y el optimizador clásico de `scipy` cuenta evaluaciones de función. Con eje lineal el peldaño más largo se comía toda la escala y los otros tres quedaban aplastados contra el margen izquierdo, que es justo donde ocurre la bajada que interesa; en log se ven los cuatro y la diferencia de presupuesto queda a la vista. No se recorta ni un punto (marcador [B-KLLOGX]).

3.5. corner_ladder_<familia>_<modelo> — la prueba visual

Archivo: corner_ladder_qmcmc_lcdm.{png,pdf}

Contornos 2D de la posterior con las marginales 1D, un color por peldaño.

Qué contesta: ¿La posterior cuántica es la misma que la clásica? A ojo, de un vistazo.

Flat Λ CDM — QMCMC quantumness ladder [steps=20000]




Figura 9: Λ CDM. Los tres peldaños —0% clásico, 50% y 100%— **caen uno encima del otro**, tanto en los contornos como en las marginales. Es la fidelidad vista directamente, sin pasar por ningún número resumido. Ésta es probablemente la figura más convincente del proyecto para una presentación.

No se pueden rehacer. Los corner necesitan las *cadenas*, y las cadenas no se guardan en el CSV. Las que existen son las de la corrida original: si se pierde la carpeta, hay que volver a correr.

3.6. corner_ladder_1to1_* — peldaño contra peldaño

Archivo: corner_ladder_1to1_qvmc_lcdm_q100.{png,pdf}

El mismo corner pero de a dos: un peldaño cuántico contra su referencia clásica.

Qué contesta: Cuando en el corner completo se encima todo, ¿cuál es exactamente la discrepancia de *este* peldaño?

Flat Λ CDM — QVMC 100% vs classical [iters=15000, nqpp=3] (cell-jittered)




Figura 10: QVMC 100% contra el clásico. Aquí es donde se ve la sub-dispersión del variacional: los contornos cuánticos son *más angostos*. Por eso esta figura acompaña bien a *incertidumbre_reportada*.

4. Por tarea: los genéticos

Viven dentro de `genetic_*/model_*/`.

4.1. `fitness_<modelo>_fitness`

Archivo: `fitness_lcdm_fitness.{png,pdf}`

Mejor χ^2 de la población contra generación, una curva por peldaño.

Qué contesta: ¿Se estancó el genético, y en qué valor acabó cada peldaño?




Figura 11: Λ CDM, $n_b = 6$. Todo el descenso ocurre en las primeras ~ 5 generaciones; las 115 restantes sólo fluctúan. Los valores finales están anotados a la derecha: CGA, QGA 0% y QGA 33% terminan en 1064,610 y los de 67% y 100% en 1064,643 — una diferencia de 0,033 en χ^2 , treinta veces por debajo del umbral de relevancia $\Delta\chi^2 = 1$.

Detalle importante: las curvas gruesas de arriba son el *mejor de la población generación a generación*, y las líneas planas de abajo son el *mejor histórico*. No son lo mismo; el resultado reportado es el segundo.

4.2. `genetic_convergence_<modelo>`

Archivo: `genetic_convergence_lcdm_genetic_convergence.{png,pdf}`

Qué contesta: Cómo se encoge la población alrededor del mejor individuo.

Flat Λ CDM — genetic convergence and final estimate
top: best individual per generation · dotted line: fiducial
bottom: fitness-weighted mean $\pm$ weighted spread (same numbers as the CSV); tick = MAP. This bar is optimizer convergence spread, NOT a credible interval.




Figura 12: Diagnóstico del optimizador. **Cuidado:** la dispersión que se ve aquí **no es una barra de error**. Un genético converge a un punto; que la población se apriete no dice nada sobre cuánta incertidumbre tiene el parámetro.

5. El eje de ruido

Viven en `figuras_*/ruido_*/`. Se generan con `graficas_ruido.py`. Son dos cortes de los mismos datos.

5.1. Las métricas, y qué cuenta como alarmante

métrica	qué es	alarma
desplazamiento	$\max_p \Delta p / \sigma(\text{ideal})$	pasar de 1
acceptance	fracción de pasos aceptados	que se desplome
final_KL	KL al terminar el entrenamiento	que suba mucho
chi2_grid	χ^2 del mejor punto de rejilla, sin refinar	que suba
Time_s	tiempo de pared	dónde está el salto

Sólo el desplazamiento mide ciencia. Las otras cuatro son diagnósticos internos: pueden empeorar bastante sin que los parámetros se muevan, y de hecho es lo que suele pasar. Un KL que sube al doble con ruido no significa que el resultado cosmológico esté mal.

Las barras rayadas son none-counts: el control *sin* ruido pero con el mismo número de disparos que las celdas ruidosas. Nunca compares none contra un peldaño ruidoso sin mirar primero none-counts: si no, estás confundiendo el efecto del ruido con el del muestreo finito.

5.2. ruido_vs_rejilla_<familia>_<modelo>_<métrica>

Archivo: `ruido_vs_rejilla_samplers_lcdm_desplazamiento.{png,pdf}`

Un panel por método. Eje x : `nqpp` o `n_bits`. Una curva por peldaño de ruido.

Qué contesta: ¿El daño del ruido **empeora** al crecer el registro?




Figura 13: ACDM. Casi todo está pegado al cero. Las excepciones son QVMC 67% y 100% bajo FakeBrisbane (verde), que suben con pendiente fuerte y **cruzan la línea de 1σ en $nqpp=4$** .

Ésta es la figura que contesta la pregunta importante del eje de ruido. Una curva ruidosa *plana* pero desplazada es un sesgo fijo, molesto pero acotado. Una curva ruidosa que *se separa hacia la derecha* es mucho peor: dice que el método se degrada conforme crece el registro, o sea que en hardware real no escala. Es lo que está pasando con el QVMC bajo un backend calibrado, y hay que decirlo.

5.3. ruido_fijo_<familia>_<modelo>_<rejilla>

Archivo: ruido_fijo_samplers_lcdm_nqpp4.{png,pdf}

Rejilla fija, los peldaños de ruido lado a lado, las cuatro métricas apiladas.

Qué contesta: En esta celda concreta, ¿qué cuesta el ruido, en cada cosa a la vez?




Figura 14: Λ CDM, $n_{\text{qpp}}=4$. La lectura de conjunto es la conclusión del eje entero: el desplazamiento está en el suelo salvo dos barras verdes (QVMC 67% y 100% con FakeBrisbane, ambas por encima de 1σ); la aceptación es plana; el KL sube con el ruido; y el tiempo sube muchísimo más — de 10^2 a 10^5 segundos. **El ruido cuesta sobre todo tiempo, y sólo en casos contados mueve la física.**

6. Las comparaciones

Viven en `figuras_*/comparacion_*/`. Se generan con `comparar_algoritmos.py`. Son cinco, y son las que van al paper.

6.1. `eficiencia_QMCMC100` y `eficiencia_QMCMC50`

Archivo: `eficiencia_QMCMC100`.{png,pdf}

Dos paneles: (a) razón de ESS, (b) razón de ESS por segundo. Una barra por modelo. Morado = gana el cuántico, café = gana el clásico.

Qué contesta: ¿El muestreador cuántico produce más muestras independientes por paso que el clásico?




Figura 15: Dos de cinco modelos quedan a favor del cuántico (PEDE 1,063, LCDM 1,012) y tres en contra (CPL 0,917, GEDE 0,932, WCDM 0,948). La conclusión honesta es **empate**.

El panel (a) es la **comparación honesta**; es independiente del hardware. El panel (b) mide el costo de Aer, no el del cómputo cuántico, y **no sostiene ninguna afirmación sobre velocidad real**. Está en la figura porque omitirlo sería peor, no porque se pueda citar como resultado.

Y hay una explicación limpia para el empate, que conviene tener lista: la propuesta cuántica *no sabe dónde está la posterior* —los ángulos son aleatorios, el circuito nunca vio los datos—, así que no tiene mecanismo por el cual pudiera llegar más rápido. Una razón de $\approx 0,95$ es exactamente lo que se espera.

6.2. `incertidumbre_reportada`

Archivo: `incertidumbre_reportada`.{png,pdf}

$\sigma(\text{método})/\sigma(\text{Classical MCMC})$, un punto por parámetro, la barra vertical es la mediana sobre parámetros.

Qué contesta: ¿La barra de error que reporta cada método es la correcta?




Figura 16: Los dos peldaños del QMCMC están sobre el 1: de acuerdo con la referencia. Todos los del QVMC están a la izquierda, y bajan al subir la escalera: 0,82 con un componente cuántico, 0,65 con dos o tres.

Por debajo de 1 no es precisión: es sesgo. Si un método reporta $\pm 0,0035$ donde la verdad es $\pm 0,0269$, un modelo que está a 2σ aparece a 15σ y uno anuncia una tensión que no existe.

Dos cosas que hay que decir al reportarla. Primero: la fila *Classical VI* ya está en 0,80, y ahí **no hay nada cuántico** — es la asimetría de $KL(q||p)$, que castiga poner probabilidad donde la posterior no tiene y casi no castiga dejar de ponerla donde sí hay, de modo que el óptimo se mete en el modo y se encoge. Lo que aporta el marco de ablación es medir que los componentes cuánticos *empeoran* ese sesgo. Segundo: estos números son **medianas sobre celdas**, y celda por celda la razón va de 0,34 a 1,34. Reporta la mediana y la dispersión; un árbitro que mire celda por celda va a ver ese 1,34.

6.3. genetico_chi2grid

Archivo: genetico_chi2grid.{png,pdf}

$\Delta\chi^2$ del mejor punto de rejilla contra el CGA, un panel por modelo, eje $x = n_bits$, escala simétrica logarítmica. Negativo significa que el cuántico encontró mejor punto. La punteada marca $\Delta\chi^2 = 1$.

Qué contesta: ¿El genético cuántico encuentra un punto mejor o peor, y cuánto?




Figura 17: El peldaño de 33 % (azul) está pegado al cero en los cinco modelos. Los de 67 % y 100 % empiezan por encima de $\Delta\chi^2 = 1$ con $n_b = 4$ y **caen un orden de magnitud por cada bit que se añade**, hasta $\sim 10^{-3}$ con $n_b = 8$.

La lectura tiene dos mitades y las dos hay que reportarlas: el signo es **consistente en las 24 celdas** — el cuántico nunca gana, lo cual es un efecto sistemático real — pero la **magnitud se desvanece al refinar la rejilla**, y sólo 5 de 24 celdas pasan el umbral de relevancia. Decir sólo lo primero exagera; decir sólo lo segundo esconde un sesgo real.

6.4. modelos_aic_bic

Archivo: modelos_aic_bic.{png,pdf}

ΔAIC y ΔBIC por modelo cosmológico. Las puntuadas están en 2, 6 y 10, que es la escala de Jeffreys.

Qué contesta: ¿Qué modelo cosmológico prefieren los datos?




Figura 18: Gana CPL por AIC ($\Delta = 0$, con ΛCDM a 1,97) y ΛCDM por BIC ($\Delta = 0$, con todo lo demás a 6,22 o más). PEDE queda rechazado por los dos criterios (16,27 y 14,30).

Que los dos criterios discrepen no es un problema, y hay que explicarlo en vez de esconderlo: el BIC cobra $\ln(1099) = 7,0$ unidades de χ^2 por parámetro extra y el AIC sólo 2. El parámetro de más de CPL compra una mejora intermedia — le alcanza al AIC y no al BIC.

Cuidado al leerla: los dos paneles están ordenados por su *propio* criterio, así que las filas no están en el mismo orden en (a) y en (b). Comparar a la misma altura entre paneles es un error.

Y un aviso sobre χ^2_v : los cinco modelos dan entre 0,967 y 0,984. Todos ajustan de forma aceptable, y por eso χ^2_v **no sirve para elegir entre ellos**. Para eso están el AIC y el BIC.

7. Índice rápido

archivo	dónde vive	qué contesta
convergence_<m>	hpc_*/	¿basta los qubits que usé?
cost_<m>	hpc_*/	qué cuesta en el simulador
convergence_<m>_genetico	hpc_*/	¿cuántos bits por gen hacen falta?
cost_<m>_genetico	hpc_*/	dónde se vuelve impagable el QGA
ladder_trends_<m>	samplers_*/model_*/	qué cambia al encender lo cuántico
ladder_summary_<m>	samplers_*/model_*/	los números exactos, en tabla
ladder_rhat_qmcmc_<m>	samplers_*/model_*/	¿convergió la cadena?
ladder_kl_qvmc_<m>	samplers_*/model_*/	el techo de expresividad del ansatz
corner_ladder_<f>_<m>	samplers_*/model_*/	la fidelidad, vista a ojo
corner_ladder_1to1_*	samplers_*/model_*/	la discrepancia de un peldaño
fitness_<m>_fitness	genetic_*/model_*/	¿se estancó el genético?
genetic_convergence_<m>	genetic_*/model_*/	cómo se encoge la población
ruido_vs_rejilla_*	figuras_*/ruido_*/	¿el ruido empeora con el registro?
ruido_fijo_*	figuras_*/ruido_*/	qué cuesta el ruido en esta celda
eficiencia_QMCMC*	figuras_*/comparacion_*/	¿más muestras independientes por paso?
incertidumbre_reportada	figuras_*/comparacion_*/	¿la barra de error es la correcta?
genetico_chi2grid	figuras_*/comparacion_*/	¿el QGA encuentra mejor punto?
modelos_aic_bic	figuras_*/comparacion_*/	qué modelo prefieren los datos

8. Cómo rehacerlas todas

Ningún paso recalcula nada científico; todos leen los CSV y los logs que la campaña ya escribió.

qué rehace	comando
convergence_*, cost_*	python cosmo_hpc_runner.py --plot-only CAMPANA
ladder_*	python cosmo_modular_quantum.py --replot-ladder CAMPANA/samplers_*/model_*/resultados_config.csv
el eje de ruido	python graficas_ruido.py CAMPANA --salida SALIDA
las comparaciones	python comparar_algoritmos.py CAMPANA --salida SALIDA
todo lo anterior	bash rehacer_todo.sh CAMPANA

Dos avisos sobre rehacer:

1. Los ladder_rhat y ladder_kl **necesitan el log de la tarea**, no sólo el CSV: el $\hat{R}$ por paso y el KL por iteración no son columnas. Si el log no está a mano, esas dos figuras se omiten *en silencio* y el título de las otras sale con steps=? | iters=?. Ese signo de interrogación es la señal de que faltan figuras.
2. Los corner no se pueden rehacer nunca: necesitan las cadenas.

9. Lo que no hay que hacer con estas figuras

1. **No leer el ESS como métrica de calidad en el variacional.** Ahí vale 12288 en todos los peldaños porque es el número de disparos, no una medida de nada.
2. **No comparar las *_std del genético con las σ de los muestreadores.** El genético converge a un punto; su desviación mide encogimiento de población, no incertidumbre del parámetro. Por eso el script de comparación las imprime en otra sección y con un aviso.

3. **No citar una celda cuyo $\hat{R}$ no bajó del umbral.**
4. **No comparar none contra un peldaño ruidoso** sin mirar antes none-counts.
5. **No usar la razón ESS/s como afirmación sobre hardware.** Mide Aer.
6. **No reportar una diferencia pequeña sin el estudio de semillas.** Hoy ninguna celda tiene dos semillas, así que la razón de ESS de 0,948 y los $\Delta\chi^2$ del genético por debajo de 1 **todavía no son defendibles.** Es el hueco más grande que queda.